

ANÁLISE EXPLORATÓRIA DE DADOS

Abastecimento de Água no Estado de São Paulo

Distribuição por Regiões Metropolitanas — Censo Demográfico de 2010

Etapas 2 — Definição do Produto Analítico

Fonte: IBGE — Censo Demográfico 2010

Abril de 2026

Sumário

Sumário	2
1. Glossário.....	3
2. Objetivo do Estudo.....	4
2.1. Contexto	4
2.2. Objetivo Geral.....	4
2.3. Objetivos Específicos	4
3. Apresentação da Fonte de Dados.....	5
3.1. Origem dos Dados.....	5
3.2. Fonte Primária	5
3.3. Recorte Adotado.....	5
4. Problema de Pesquisa	6
4.1. Pergunta Central	6
4.2. Perguntas Secundárias	6
4.3. Solução a Ser Desenvolvida.....	6
5. Apresentação dos Metadados.....	7
5.1. Estrutura do Conjunto de Dados.....	7
5.2. Características Gerais	7
5.3. Etapas de Limpeza Aplicadas.....	7
6. Análise Exploratória de Dados	9
6.1. Distribuição das Formas de Abastecimento no Estado	9
6.2. Distribuição Populacional por Região	11
6.3. Estatísticas Descritivas — Rede Geral	12
6.4. Análise de Outliers	12
6.5. Análise de Correlação	14
6.6. Síntese dos Achados.....	14
7. Considerações Finais.....	16
Referências.....	16

1. Glossário

Esta seção apresenta os termos técnicos utilizados ao longo deste estudo, juntamente com seus respectivos significados e sinônimos. O objetivo é garantir que o leitor — mesmo sem familiaridade prévia com o tema — consiga acompanhar as discussões com clareza.

Termo	Significado / Sinônimo
Domicílio	Unidade habitacional permanente onde reside um ou mais moradores; equivale a 'residência' ou 'lar'.
RIDE	Região Integrada de Desenvolvimento Econômico — recorte territorial usado pelo IBGE para análises regionais.
Região Metropolitana (RM)	Agrupamento de municípios vizinhos que formam um polo urbano único para fins de planejamento.
Rede geral de abastecimento	Sistema público encanado de distribuição de água tratada (sinônimo: rede pública, água encanada).
Poço ou nascente	Fonte de água subterrânea ou superficial natural utilizada como abastecimento alternativo.
Carro-pipa	Caminhão-tanque que entrega água onde não há rede pública; comum em situações de escassez.
Cisterna	Reservatório utilizado para armazenamento de água da chuva.
IBGE	Instituto Brasileiro de Geografia e Estatística — órgão responsável pelo Censo Demográfico.
Censo Demográfico	Levantamento nacional que coleta dados de toda a população brasileira a cada 10 anos.
Outlier	Valor atípico que se afasta significativamente do padrão observado nos demais dados.
IQR	Intervalo Interquartil — diferença entre o 3º e o 1º quartil; mede a dispersão dos 50% centrais.
CV	Coeficiente de Variação — razão entre desvio-padrão e média, em %.

2. Objetivo do Estudo

O presente trabalho consiste em uma análise exploratória de dados (AED) sobre as formas de abastecimento de água nos domicílios do estado de São Paulo, tendo como base o Censo Demográfico de 2010, realizado pelo Instituto Brasileiro de Geografia e Estatística (IBGE).

2.1. Contexto

O acesso à água tratada é um dos indicadores mais relevantes de qualidade de vida e desenvolvimento humano. A Organização das Nações Unidas (ONU) reconhece o acesso à água potável como um direito humano fundamental, e a forma como uma população é abastecida revela muito sobre sua infraestrutura urbana, condições sanitárias e desigualdades regionais.

São Paulo é o estado mais populoso e economicamente desenvolvido do Brasil, mas mesmo em seu território é possível observar contrastes significativos entre as regiões metropolitanas. Enquanto a capital concentra a maior parte da população atendida pela rede geral, regiões mais afastadas ainda dependem de fontes alternativas, como poços, rios, captação de chuva e até carros-pipa.

2.2. Objetivo Geral

Realizar uma análise exploratória do conjunto de dados do IBGE referente às formas de abastecimento de água nos domicílios do estado de São Paulo, identificando padrões, concentrações, desigualdades regionais e possíveis pontos de atenção para políticas públicas.

2.3. Objetivos Específicos

- Limpar e padronizar o conjunto de dados original (codificação, valores ausentes e nomes inconsistentes).
- Calcular estatísticas descritivas (média, mediana, quartis, desvio-padrão, coeficiente de variação) para cada forma de abastecimento.
- Identificar a distribuição percentual das formas de abastecimento no estado.
- Detectar regiões com comportamento atípico (outliers) em relação ao padrão estadual.
- Analisar a correlação entre as diferentes formas de abastecimento.
- Apresentar visualizações gráficas que facilitem a comunicação dos achados.

3. Apresentação da Fonte de Dados

3.1. Origem dos Dados

Os dados utilizados neste estudo foram obtidos diretamente do site oficial do IBGE (Instituto Brasileiro de Geografia e Estatística), órgão federal responsável pela produção e disseminação das estatísticas oficiais do Brasil. O IBGE é a principal fonte de informação demográfica, social e econômica do país, conduzindo o Censo Demográfico a cada dez anos.

3.2. Fonte Primária

A fonte primária é o Censo Demográfico de 2010, conduzido pelo IBGE, que coletou informações sobre a totalidade dos domicílios brasileiros. As informações sobre abastecimento de água foram registradas no questionário aplicado aos moradores e tabuladas por município, agrupadas posteriormente em recortes regionais (Regiões Metropolitanas e RIDEs).

3.3. Recorte Adotado

Para este trabalho, foi selecionado o recorte do estado de São Paulo, dividido em 12 regiões metropolitanas e áreas integradas:

- Região Metropolitana de São Paulo
- Baixada Santista
- Campinas
- Vale do Paraíba e Litoral Norte (subdividido em 5 sub-regiões)
- Jundiaí
- Piracicaba
- Sorocaba
- Interior (municípios fora das regiões metropolitanas)

A linha originalmente intitulada "Ignorado - SP" (35000) foi removida durante a etapa de limpeza por não conter informações úteis (todos os campos eram nulos).

4. Problema de Pesquisa

4.1. Pergunta Central

Como se distribui o abastecimento de água entre as regiões metropolitanas do estado de São Paulo, e quais são as desigualdades e padrões observáveis nessa distribuição?

4.2. Perguntas Secundárias

- Qual é a representatividade da rede geral de abastecimento em comparação com fontes alternativas?
- Existem regiões com dependência atípica de fontes não convencionais (rios, carros-pipa, captação de chuva)?
- Há concentração populacional em uma única região? Como isso impacta as estatísticas?
- As diferentes formas de abastecimento estão correlacionadas entre si? Regiões com mais rede geral têm menos uso de fontes alternativas?
- Quais regiões podem ser consideradas mais vulneráveis quanto ao acesso à água tratada?

4.3. Solução a Ser Desenvolvida

Será desenvolvido um produto analítico em forma de relatório descritivo, acompanhado de visualizações gráficas (gráficos de barras, gráfico de pizza e mapa de calor de correlação), capaz de responder às perguntas acima e fornecer subsídios visuais para discussão acadêmica e tomada de decisão. O pipeline do projeto consiste em: (1) coleta dos dados brutos no IBGE; (2) limpeza e padronização com Pandas; (3) análise estatística com NumPy e Pandas; (4) visualização com Matplotlib e Seaborn; (5) consolidação dos resultados em relatório final.

5. Apresentação dos Metadados

Após a etapa de limpeza, o conjunto de dados final é composto por 12 linhas (uma para cada região metropolitana ou recorte territorial) e 12 colunas (1 identificadora + 10 formas de abastecimento + 1 coluna de Total). Todos os valores numéricos representam quantidades de domicílios.

5.1. Estrutura do Conjunto de Dados

Coluna	Tipo	Descrição
Região Metropolitana - RIDE	Texto	Nome da região metropolitana ou recorte territorial dentro do estado de SP.
Rede geral - sem informação de canalização	Inteiro	Domicílios atendidos pela rede pública de abastecimento de água.
Poço ou nascente - sem informação de canalização	Inteiro	Domicílios abastecidos por poço ou nascente localizado dentro da propriedade.
Poço ou nascente fora da propriedade	Inteiro	Domicílios que utilizam poço ou nascente externos à propriedade.
Carro-Pipa	Inteiro	Domicílios abastecidos por entregas de caminhão-pipa.
Água da chuva armazenada em cisterna	Inteiro	Domicílios que captam chuva e armazenam em cisternas.
Água da chuva armazenada outra forma	Inteiro	Domicílios que armazenam chuva por outros meios (caixas, baldes, tonéis).
Rio, açude, lago ou igarapé	Inteiro	Domicílios que utilizam fontes hídricas superficiais.
Poço ou nascente na aldeia	Inteiro	Domicílios indígenas com poço/nascente dentro da aldeia.
Poço ou nascente fora da aldeia	Inteiro	Domicílios indígenas com poço/nascente fora da aldeia.
Outra	Inteiro	Demais formas de abastecimento não categorizadas.
Total	Inteiro	Soma de todos os domicílios da região (todas as fontes).

5.2. Características Gerais

- Dimensão: 12 linhas × 12 colunas (após limpeza).
- Tipo de dados: 1 coluna textual + 11 colunas numéricas inteiras.
- Período de referência: ano de 2010 (Censo).
- Granularidade: agregado por região metropolitana.
- Valores ausentes: nenhum (após substituição dos hífens "-" por zeros).
- Valores negativos: nenhum (auditoria confirmou consistência lógica).

5.3. Etapas de Limpeza Aplicadas

A base original, em formato CSV separado por ponto-e-vírgula com codificação latin1, apresentava: (a) cabeçalhos em três linhas iniciais e duas linhas de rodapé que precisaram ser removidas com `skiprows` e `skipfooter`; (b) caracteres acentuados corrompidos devido ao encoding; (c) hífen ("-") representando valores nulos; (d) nomes de regiões com códigos numéricos prefixados e caracteres ilegíveis. Todas essas inconsistências foram tratadas com Pandas, gerando um arquivo limpo (`DATABASE_LIMPO.csv`) usado em todas as análises subsequentes.

6. Análise Exploratória de Dados


6.1. Distribuição das Formas de Abastecimento no Estado

A primeira observação relevante é a esmagadora predominância da rede geral de abastecimento no estado de São Paulo. De um total de 40.943.200 domicílios contabilizados, mais de 38,8 milhões são atendidos pela rede pública — o que corresponde a aproximadamente 94,87% de toda a base. As demais formas, somadas, representam pouco mais de 5% do total.

Forma de abastecimento	Domicílios	% do Estado
Rede geral	38.841.362	94,87%
Poço/nascente na propriedade	1.530.301	3,74%
Poço/nascente fora da propriedade	351.623	0,86%
Outra	147.283	0,36%
Rio, açude, lago ou igarapé	34.803	0,09%
Carro-pipa	31.272	0,08%
Chuva (outra forma)	2.856	0,01%
Chuva (cisterna)	2.289	0,01%
Poço/nascente na aldeia	1.268	0,003%
Poço/nascente fora da aldeia	143	0,0003%

Em termos visuais, a distribuição percentual fica clara no gráfico de pizza a seguir, no qual a rede geral ocupa praticamente toda a área:

Distribuição das Formas de Abastecimento - SP (2010)




6.2. Distribuição Populacional por Região

A segunda observação relevante é a concentração demográfica extrema do estado. A Região Metropolitana de São Paulo, sozinha, concentra quase metade dos domicílios (47,77%). Somada à categoria "Interior (Fora RM)", as duas representam mais de 74% do total estadual. As demais 10 regiões dividem os 26% restantes.

Região	Domicílios (Total)	% do Estado
São Paulo	19.560.134	47,77%
Interior (Fora RM)	10.982.557	26,82%
Campinas	2.791.359	6,82%
Sorocaba	1.712.620	4,18%
Baixada Santista	1.654.236	4,04%
Piracicaba	1.300.352	3,18%
Vale do Paraíba 1	971.612	2,37%
Jundiaí	696.154	1,70%
Vale do Paraíba 2	549.682	1,34%
Vale do Paraíba 3	324.560	0,79%
Vale do Paraíba 5	279.858	0,68%
Vale do Paraíba 4	120.076	0,29%
TOTAL	40.943.200	100,00%

O gráfico de barras horizontal a seguir evidencia visualmente essa concentração:



6.3. Estatísticas Descritivas — Rede Geral

A coluna "Rede geral" é a mais relevante do dataset por concentrar a quase totalidade dos domicílios. Suas estatísticas descritivas revelam um aspecto importante: a enorme dispersão entre as regiões, com coeficiente de variação de 175,32%, indicando que os dados estão extremamente espalhados em torno da média.

Medida	Valor
Contagem (regiões)	12
Média	3.236.780,17 domicílios
Mediana	1.086.453,50 domicílios
Mínimo	108.390 (Vale do Paraíba 4)
1º Quartil (Q1)	456.298,50
3º Quartil (Q3)	1.863.826,00
Máximo	19.084.981 (São Paulo)
Desvio Padrão	5.674.692,00
Coef. de Variação (CV)	175,32% (alta dispersão)

A média (~3,2 milhões) é quase três vezes maior que a mediana (~1,08 milhão), o que é um indicativo clássico de assimetria positiva: existem poucos valores muito altos (a Região Metropolitana de São Paulo, principalmente) que puxam a média para cima, enquanto a maioria das regiões tem valores muito menores.

6.4. Análise de Outliers

A detecção de outliers foi realizada pelo método do Intervalo Interquartil (IQR), considerando como outlier qualquer valor superior a $Q3 + 1,5 \times IQR$. Os resultados confirmam a hipótese de assimetria: praticamente todas as colunas apresentam outliers, e as regiões "São Paulo" e "Interior (Fora RM)" aparecem repetidamente como pontos atípicos.


Coluna	Limite Sup. ($Q3 + 1.5 \cdot IQR$)	Outliers identificados
Rede geral	3.975.117	São Paulo (19.084.981); Interior (10.022.582)
Poço/nasc. na propriedade	240.629	São Paulo (296.324); Interior (772.397)
Poço/nasc. fora da propriedade	55.297	Interior (158.645)
Carro-Pipa	4.512	São Paulo (20.671)
Chuva (cisterna)	220	São Paulo (555); Interior (1.376)
Chuva (outra forma)	348	São Paulo (1.505); Baixada Santista (701)
Rio/açude/lago/igarapé	8.435	Vale do Paraíba 5 (12.117); Interior (10.398)
Poço/nasc. na aldeia	44	São Paulo (562); Interior (661)
Poço/nasc. fora da aldeia	0	Vale do Paraíba 5 (141); Interior (2)

Outra	16.987	São Paulo (100.156); Baixada Santista (21.964)
-------	--------	--

É importante observar que esses outliers não são erros — eles refletem a realidade demográfica do estado. A Região Metropolitana de São Paulo é, de fato, um caso atípico em termos populacionais, e o agregado "Interior" cobre um número muito grande de municípios. Já o destaque da região "Vale do Paraíba 5" no uso de água de rios/lagos/igarapés sugere maior dependência de fontes naturais nessa sub-região, possivelmente por características rurais ou geográficas específicas.

6.5. Análise de Correlação

Para investigar se há relação entre as diferentes formas de abastecimento, foi gerada uma matriz de correlação de Pearson, visualizada como mapa de calor:



Observações importantes sobre a matriz de correlação:

- A maioria das variáveis apresenta correlação positiva forte entre si. Isso ocorre porque as colunas são contagens absolutas — regiões mais populosas tendem a ter mais domicílios em todas as categorias simultaneamente. Não se trata, portanto, de uma relação causal entre as fontes.
- Para uma análise causal real ("regiões com mais rede geral usam menos poços?"), seria necessário converter os valores absolutos em proporções relativas ao total da própria região — uma análise que pode ser feita em uma etapa futura do projeto.
- As correlações mais baixas envolvem as colunas "Poço na aldeia" e "Poço fora da aldeia", que possuem muitos valores zero (categorias específicas para população indígena, com presença marginal no estado).

6.6. Síntese dos Achados

A análise exploratória permite consolidar as seguintes conclusões:

- São Paulo possui cobertura quase universal de rede geral de água: ~94,87% dos domicílios. Esse é um indicador positivo de infraestrutura, embora ainda existam aproximadamente 2,1 milhões de domicílios dependentes de fontes alternativas.
- A concentração populacional na Região Metropolitana de São Paulo distorce significativamente as estatísticas agregadas, tornando essa região um outlier permanente em praticamente todas as análises absolutas.
- O recorte "Interior (Fora RM)" também aparece repetidamente como atípico, especialmente em formas alternativas de abastecimento (poços, captação de chuva), o que é coerente com o perfil mais rural dessas localidades.

- O Vale do Paraíba 5 destaca-se pelo uso de rios e lagos como fonte de água, indicando uma dependência hídrica natural que pode ser objeto de estudo aprofundado.
- As fontes mais precárias (carro-pipa, água de rio, captação de chuva improvisada) somadas representam pouco mais de 0,1% do total estadual — número baixo, mas que ainda equivale a dezenas de milhares de famílias.

7. Considerações Finais

A análise exploratória cumpre seu papel ao mapear o panorama do abastecimento de água em São Paulo no Censo de 2010. O estado apresenta um cenário positivo em termos de cobertura geral, mas a desigualdade entre regiões e a existência de pontos de vulnerabilidade reforçam a importância de estudos regionalizados.

Para a próxima etapa do projeto, sugere-se: (a) calcular a participação relativa de cada fonte dentro de cada região (e não apenas em valores absolutos), permitindo comparação justa entre regiões grandes e pequenas; (b) cruzar esses dados com indicadores socioeconômicos (renda, IDH, urbanização); (c) comparar com o Censo de 2022 para avaliar a evolução da cobertura ao longo de 12 anos; (d) construir um produto analítico interativo (dashboard) que permita ao usuário explorar os dados por região.

Este relatório consolida a Etapa 2 do projeto e estabelece as bases para o desenvolvimento dos produtos analíticos previstos para as etapas seguintes.

Referências

- IBGE — Instituto Brasileiro de Geografia e Estatística. Censo Demográfico 2010. Disponível em: <https://www.ibge.gov.br/>.
- McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proceedings of the 9th Python in Science Conference.
- Hunter, J. D. (2007). Matplotlib: A 2D Graphics Environment. Computing in Science & Engineering.
- Waskom, M. L. (2021). Seaborn: statistical data visualization. Journal of Open Source Software.