

Universidade Presbiteriana Mackenzie

Banco de dados – Projeto Aplicado I

Gabriel Lucca Simionato

Gabriela Wanda Rodrigues dos Santos

Guilherme Cunha Oliveira

**ABASTECIMENTO DE ÁGUA NAS REGIÕES METROPOLITANAS DO ESTADO
DE SÃO PAULO:**

Uma análise exploratória dos dados do Censo Demográfico 2010

São Paulo

2026

Gabriel Lucca Simionato
Gabriela Wanda Rodrigues dos Santos
Guilherme Cunha Oliveira

**ABASTECIMENTO DE ÁGUA NAS REGIÕES METROPOLITANAS DO ESTADO
DE SÃO PAULO:
Uma análise exploratória dos dados do Censo Demográfico 2010**

Trabalho apresentado à disciplina Projeto Aplicado I
do curso Banco de dados da Mackenzie, como
requisito parcial para avaliação. Orientador(a): Prof.(a)
Ismar.

São Paulo
2026

SUMÁRIO

1 OBJETIVO DE ESTUDO	5
2 APRESENTAÇÃO DA ORGANIZAÇÃO E PROBLEMA DE PESQUISA	6
3 APRESENTAÇÃO DOS METADADOS E ANÁLISE EXPLORATÓRIA DE DADOS	7
3.1 Metadados e tratamento da base	7
3.2 Estatística descritiva	7
3.3 Distribuição das formas de abastecimento	8
3.4 Cobertura da rede geral por região	8
3.5 Correlação entre as formas de abastecimento	9
3.6 Detecção de outliers	10
4 SÍNTESE DA SOLUÇÃO ANALÍTICA	11
REFERÊNCIAS	12

GLOSSÁRIO

Reúnem-se a seguir os principais termos técnicos empregados neste relatório, em ordem alfabética.

Abastecimento de água: conjunto de formas pelas quais os domicílios obtêm água para consumo — rede geral, poços, nascentes, carros-pipa e fontes superficiais.

Análise exploratória de dados (AED): etapa inicial da investigação estatística voltada a descrever, resumir e visualizar os dados antes de qualquer modelagem.

Censo Demográfico: levantamento que recenseia toda a população de um território, realizado no Brasil pelo IBGE.

Coeficiente de variação (CV): medida relativa de dispersão, em percentual, obtida pela razão entre o desvio padrão e a média.

Correlação de Pearson: coeficiente que mede a força e o sentido da associação linear entre duas variáveis quantitativas, variando de -1 a $+1$.

Desvio padrão: medida de dispersão que indica o afastamento médio dos valores em relação à média.

IBGE: Instituto Brasileiro de Geografia e Estatística, órgão responsável pelas estatísticas oficiais do país.

Intervalo interquartil (IQR): diferença entre o terceiro e o primeiro quartil; base da regra de detecção de outliers adotada neste estudo.

Mediana: valor que divide ao meio um conjunto ordenado de dados.

Metadados: informações que descrevem a estrutura, a origem e o significado dos dados (colunas, tipos e unidades).

Outlier: observação que se afasta de forma atípica do padrão geral dos dados.

Rede geral: forma de abastecimento na qual a água chega ao domicílio por sistema público de distribuição.

Região Integrada de Desenvolvimento (RIDE): recorte territorial que reúne municípios de interesse comum para fins de planejamento.

Região Metropolitana (RM): agrupamento de municípios conurbados em torno de um polo, tratado como unidade de planejamento.

1 OBJETIVO DE ESTUDO

Este trabalho tem por objetivo geral caracterizar, por meio de uma análise exploratória de dados, as formas de abastecimento de água nas Regiões Metropolitanas e na Região Integrada de Desenvolvimento (RIDE) do Estado de São Paulo, a partir do Censo Demográfico 2010 (IBGE, 2010), evidenciando as desigualdades regionais no acesso à rede geral.

De forma específica, o estudo se propõe a: (i) descrever a base de dados e seus metadados, bem como o tratamento aplicado; (ii) quantificar a participação de cada forma de abastecimento no total de moradores; (iii) comparar a cobertura da rede geral entre as regiões; (iv) investigar correlações entre as diferentes formas de abastecimento; e (v) identificar valores atípicos (outliers) que revelem situações de carência.

2 APRESENTAÇÃO DA ORGANIZAÇÃO E PROBLEMA DE PESQUISA

A organização de estudo é o **Instituto Brasileiro de Geografia e Estatística (IBGE)**, autarquia federal responsável pela produção e pela disseminação das estatísticas oficiais do país. Entre seus levantamentos, o Censo Demográfico recenseia a totalidade da população, o que confere à base utilizada uma cobertura completa, e não amostral. Os dados analisados correspondem ao recorte de moradores por Região Metropolitana e RIDE, segundo a forma de abastecimento de água, no Estado de São Paulo (IBGE, 2010).

O acesso à água tratada é um indicador direto de saneamento básico, de saúde pública e de desigualdade territorial. Embora os dados sejam públicos, eles são disponibilizados de maneira agregada e bruta, o que dificulta a leitura imediata de onde o abastecimento adequado falha e de quais alternativas surgem nesses territórios. Daí decorre o problema de pesquisa que orienta o trabalho:

Como se distribui o abastecimento de água entre as regiões do Estado de São Paulo e quais delas ficam aquém da cobertura por rede geral — e o que passa a abastecer a população onde essa rede não chega?

Responder a essa pergunta justifica-se por transformar um conjunto de números agregados em um diagnóstico capaz de orientar a priorização de investimentos em infraestrutura e saneamento.

3 APRESENTAÇÃO DOS METADADOS E ANÁLISE EXPLORATÓRIA DE DADOS

3.1 Metadados e tratamento da base

A base é composta por 12 regiões (linhas de análise) e 11 variáveis numéricas — dez formas de abastecimento e uma coluna de total —, além da coluna categórica que identifica a região. O universo abrange 40.943.200 moradores. O Quadro 1 sintetiza os metadados.

Quadro 1 – Metadados da base de dados

Coluna	Tipo	Descrição
Região Metropolitana – RIDE	Texto	Nome da região (chave de análise).
Rede geral	Inteiro	Moradores atendidos por rede pública de distribuição.
Poço ou nascente (na propriedade)	Inteiro	Moradores abastecidos por poço/nascente no terreno.
Poço ou nascente fora da propriedade	Inteiro	Moradores que buscam água em poço/nascente externo.
Carro-pipa	Inteiro	Moradores abastecidos por caminhão-pipa.
Chuva em cisterna	Inteiro	Água de chuva armazenada em cisterna.
Chuva (outra forma)	Inteiro	Água de chuva armazenada de outras maneiras.
Rio, açude, lago ou igarapé	Inteiro	Moradores que captam água de fontes superficiais.
Poço ou nascente na aldeia	Inteiro	Forma específica de áreas indígenas.
Poço ou nascente fora da aldeia	Inteiro	Forma específica de áreas indígenas.
Outra	Inteiro	Demais formas não classificadas.
Total	Inteiro	Soma de moradores da região (coluna de controle).

Fonte: Elaborado pelos autores com base em IBGE (2010).

O arquivo original encontrava-se codificado em Latin-1, com ponto e vírgula como separador e o caractere “—” representando ausência de registros. No tratamento, converteu-se a codificação para UTF-8, padronizaram-se os rótulos das regiões, substituíram-se as ausências por zero e removeu-se a linha de total, de modo a não distorcer as medidas estatísticas. A auditoria de integridade não encontrou valores nulos nem valores negativos logicamente incorretos.

3.2 Estatística descritiva


As medidas descritivas evidenciam a forte heterogeneidade entre as regiões. Para a rede geral, a média de moradores atendidos é de 3.236.780, mas a mediana é

de apenas 1.086.454 — a distância entre as duas medidas já antecipa a presença de regiões muito maiores que as demais. O coeficiente de variação da rede geral alcança 175%, o que confirma uma dispersão elevada e indica que o porte populacional das regiões é bastante desigual.

3.3 Distribuição das formas de abastecimento

Quando se observa o estado como um todo, a rede geral é largamente predominante, respondendo por 94,87% dos moradores. A segunda forma mais frequente é o poço ou nascente na propriedade, com 3,74%; todas as demais somadas não alcançam 1,1% e só se tornam relevantes em territórios específicos. A Figura 1 ilustra essa distribuição.

Figura 1 – Distribuição percentual das formas de abastecimento de água — Estado de São Paulo (2010)




Fonte: Elaborada pelos autores com base em IBGE (2010).

O percentual elevado, porém, esconde uma multidão: os 5,13% sem rede geral equivalem a 2.101.838 moradores — população superior à de toda a Baixada Santista.

3.4 Cobertura da rede geral por região

Ao desagregar os 94,87% nas 12 regiões, a uniformidade desaparece. A capital lidera, com 97,6% de cobertura, enquanto o Vale do Paraíba 5 figura no extremo oposto, com 80,5% — uma diferença de 17 pontos percentuais. Sete das doze regiões ficam abaixo da média estadual. A Figura 2 ordena as regiões pela cobertura.

Figura 2 – Percentual de moradores atendidos por rede geral, por região




Fonte: Elaborada pelos autores com base em IBGE (2010).

Vale destacar que, em números absolutos, o maior contingente sem rede não está na borda do mapa, mas no agregado “Interior — fora das Regiões Metropolitanas”, com 959.975 moradores sem rede geral — mais de três vezes a população total do Vale do Paraíba 5. A carência, portanto, combina intensidade (no Vale do Paraíba 5) e volume (no interior).

3.5 Correlação entre as formas de abastecimento

A matriz de correlação de Pearson (Figura 3) mostra associações positivas fortes entre as formas de maior volume, efeito esperado do porte populacional das regiões: regiões maiores tendem a apresentar mais moradores em quase todas as categorias simultaneamente. A leitura analítica relevante, contudo, está nos contrastes: onde a rede é proporcionalmente menor, cresce o recurso a fontes superficiais (rio, açude e lago) e a poços fora da propriedade.

Figura 3 – Matriz de correlação entre as formas de abastecimento



Fonte: Elaborada pelos autores com base em IBGE (2010).

3.6 Detecção de outliers

Aplicou-se a regra do intervalo interquartil (valores acima de $Q3 + 1,5 \times IQR$) para sinalizar anomalias. Na rede geral, São Paulo e o interior aparecem como outliers de escala — extremos esperados, decorrentes do tamanho populacional, que apenas confirmam a coerência da base. Já na variável rio, açude e lago, os outliers são o Vale do Paraíba 5 (12.117 moradores) e o interior (10.398): juntas, essas duas regiões concentram 64,7% de todo o uso de fontes superficiais no estado. No Vale do Paraíba 5, ainda, 12,5% dos moradores dependem de poço fora da propriedade — a maior taxa do estado. Nesse caso, o outlier não traduz escala, e sim carência: é exatamente o ponto para onde a atenção deveria se voltar.

4 SÍNTESE DA SOLUÇÃO ANALÍTICA

A solução analítica consistiu em um pipeline reprodutível, desenvolvido em Python com as bibliotecas pandas, Matplotlib e Seaborn, organizado em quatro etapas encadeadas: limpeza e padronização da base; estatística descritiva por variável; análise de correlação; e detecção de outliers pela regra do IQR. Cada etapa foi acompanhada de verificações de integridade, garantindo que as conclusões repousem sobre dados confiáveis.

O diagnóstico responde à pergunta de pesquisa. O abastecimento no Estado de São Paulo é dominado pela rede geral (94,87%), mas essa média esconde uma desigualdade de 17 pontos entre a melhor e a pior região. A carência se manifesta de duas formas complementares — pela intensidade, no Vale do Paraíba 5, e pelo volume, no interior — e, onde a rede não chega, a população recorre a alternativas mais precárias, como poços fora da propriedade e fontes superficiais. Recomenda-se, assim, priorizar essas regiões em políticas de saneamento; o método, por ser replicável, pode ser estendido a outros estados, censos ou indicadores.

Reconhecem-se, por fim, as limitações do estudo: os dados referem-se a 2010, o que impõe defasagem temporal; a agregação por região impede análises municipais mais finas; e parte das categorias é registrada “sem informação de canalização”, o que limita a avaliação da qualidade do abastecimento.

REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. *NBR 14724: informação e documentação — trabalhos acadêmicos — apresentação*. Rio de Janeiro: ABNT, 2011.

HUNTER, J. D. Matplotlib: a 2D graphics environment. *Computing in Science & Engineering*, v. 9, n. 3, p. 90-95, 2007.

IBGE — INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. *Censo Demográfico 2010: características da população e dos domicílios — abastecimento de água*. Rio de Janeiro: IBGE, 2010. Disponível em: <https://www.ibge.gov.br>. Acesso em: 20 jun. 2026.

McKINNEY, Wes. *Python for data analysis: data wrangling with pandas, NumPy and IPython*. 2. ed. Sebastopol: O'Reilly, 2017.

WASKOM, Michael L. Seaborn: statistical data visualization. *Journal of Open Source Software*, v. 6, n. 60, p. 3021, 2021.

Links

Github: <https://github.com/GuimeOliver/abastecimento-agua-sp-ods>

Apresentação: https://youtu.be/hu_0OhF7tSY